

鏟旂爬閬?/h1>

甯一脣鏟 誤闕剧殒璫烘杓/鎬ユ慍闕 爬鏢十墜鉅俗姆蹇冬迨鏢況笱鐔 €滄珂絳
旂 旖村嚮鏟モ€濂紅鑰岃櫨璫十瘡涓€€鏟"誤絳旖迨鑰借煩鏟? PDF 鏟熖杓旖俛岷鉅?

鏟熖璫 replay

2 answered + 1 refused

榛櫟 ☒ QA 岫"灑

qwen3-235b-a22b-instruct-2507

涓轰紆涒堝 鍋�氬畝

- 闕拑杓闕眑 ☒ 鏟 ☒ 絳旖旂京鍛岃岃 ☒ 鏟告洿閭€€瑕�€€漏 ☒ 寰櫟
嚮澶�€€過€?/li>
- 鏟 ☒ €氬京澶十伐鐔蜂細縑攢爬矜埤絳浣嚟縑闕捐脣鐔�爬矜
堦涓€鏟�澈鎟 ☒ 杓矜 c €?/li>
- 鏟或涓涓€€滅爬矜堦縑櫟悔誤鏟板帥縑団€漬仵鏟�簡涓
€鏟"氖楠�岃脣闕捐矾鉅?/li>

闕恬畧鏟蜂縑

涓 ☒ 杓璫烘杓 PDF

鏟稿績涓€灑

ask 釵?citation 釵?
PDF

琛ユ厯楠岏脣

qwen3-32b 宸查獵旖
恬氖鏟為€€

旖勸 ☒ 閱嶇倍

旖俛岷鏟為揜鏟岃笱
鐔 ☒ 硃鏟桼京
澶?/span>

鏈€鏂 龐楠劣瘉閼捐硯

鎚┒紘緝嶇隅瀹綸炔繡琛出謁澧秣笰鐙�凡缙帆獬璇俐€�繃鑽��富豐◻緞鑄◻
細 login 釵?upload 釵?ask 釵?citation 釵?PDF render 釵?refusal

1. Upload

涓婁紭璁烘杻鍒欑姘栨
婉紕淇�澶�鍒�櫳◻鏄囨
欢涓�B鐗�悽綌恒
€/span>

2. Parse

淇瀹瓊杻鐢靛緙緙澶�
侁杻鏈◻培綢榭芽杻
瀹涓�笰鏄囨◻€/span>

3. Retrieve

鐙�◻綖(三)涓鐙�崇
碗紕鏈◻憺涓◻氖
棧鐙�鎵�杻€/span>

4. Answer

妯"瀹杻涓鐙�杻杻
sed chunks 涓?
evidence quotes
杻€/span>

5. Cite

杻嶃 citation杻俐>
鐙�佸杻杻杻杻◻
杻€/span>

6. Render

鐙�璁�杻杻杻杻杻
┒涓鐙?PDF 杻瀹
侁杻杻€/span>

宸�▼錫◻篋

涓�杻杻杻杻宸�杻杻鎚┒紘緝?`.env` 杻出隅瀹�ā鐙�杻楠楠杻€/span>

捷旂ず錫◻篋

璇�◻鐙�杻杻杻杻杻
璇杻杻杻杻杻杻杻
e 伐緙杻杻杻杻
€/span>

鍒富■錫┒憺

`gold\_sample\_replay\_real\_summary\_latest.md`


鍒哄晶樺樺

2 answerable + 1 refusal

褰嶃瀹�瀹�氖

璁烘杻 / 錫┒憺杻杻涓杻杻杻杻杻€/span>

- Question 1



- Citation Jump

璇俛嵒鑣藉淠錄?PDF 鋤熠杓

- citation 涓整彀鑄⊠〉鑣伉紆鑰�嶽鑣芥墻寮€鑣燐磷楞甸潰鉅?/li>
- 楞甸潰鏹�榘紺鴻瘉鎰⊠珮浜⊠紆鑣飲竟淇濇咑鋤熠杓鑰困⊠鉅困逢鉅?/li>
- 杓鬱罇姝ㄣ𠂇欽滃淠絳旂麗淇♀€潰彊鎰愨€漏瘉鎰⊠麗鑣嬾€過€?/li>

漢圭穀鎰?/strong>

鑣⊠互蹇⊠€燐‘璉ょ爬矜塢話澶𠂇紆閭倣怙絳旂京鍛岫睞錫ㄣ墀澶槽悞鉅?/span>

漢硅瘡淪?/strong>

鑣嬾緱璫?PDF 璇俛嵒鑣岫瘡鑣eご鎖牠堪鑣存浚璇存滑鐳泣€?/span>

计算语言学

大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出作为理论语言学新兴研究工具的潜力 (Tjuatja et al., 2023)。在早期，大语言模型常被视为一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率 (Bender et al., 2021)。然而后续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信息 (Piantadosi, 2023)，区分同一个词在不同语境中的多种用法 (Petersen and Potts, 2023)，甚至可以有效表征时间和空间 (Gurnee and Tegmark, 2023)。

空间语义评测是评估自然语言处理系统对空间表达理解能力的重要手段。传统的空间语义评测方法主要依赖人工标注，但这种方法标注成本高且可扩展性差。如今，基于生成式语言模型开展评测任务逐渐成为趋势。基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？

本研究基于第四届中文空间语义理解评测任务（SpaCE2024），首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

2 相关研究

这一部分首先介绍与空间语义有关的语言学研究，然后总结自然语言处理领域关于空间语义评测的研究概况。

2.1 语言学视角下的空间语义研究

认知语言学基于人们对世界的经验和对世界进行感知和概念化的方法 (张敏, 1998)，借助隐喻等方式将抽象概念具象化。空间关系在认知语言学中占据了重要地位，是人类最早习得的能力之一 (Akhundov, 1986; Clark, 1973; 张敏, 1998; 赵艳芳, 2001)。Lakoff and Turner (1989)指出，作为一种意象图式隐喻（image schema metaphor），空间隐喻将具体的空间概念投射到抽象的语言结构中，这样的投射可以传递空间关系及其内在逻辑。这是空间语义形成的认知基础。⁰

具体来说，人在感知外部世界时总是对空间敏感，包括运动、方向、地点等信息。Langacker (1982)高度重视空间语义对语言形成的作用，提出空间语法（Space Grammar）。Jackendoff (1983)的主题关系假设（Thematic Relations Hypothesis, TRH）认为人类语言概念结构中的事件（event）和状态（state）都是通过空间概念化组织起来的，所有语义场内的关系都类似空间组织关系。Lakoff (1987)的形式空间化假设（SFH）与之类似，并且更进一步从空间语义的视角讨论了一些基本句型的形成。Johnson (1987)概括出了和空间语义相关的27个最重要的意象图式，认为这是人类空间范畴推理的基础。Pütz and Dirven (1996)也指出地点位置对人类概念的形成有基础性作用。很多和空间范畴相关的概念也已经成为认知语言学中的重要工具和分析手段，如Talmy (1983)的图形-背景理论、Langacker (1987)的“基体-侧面”“射体-界标”关系等。

在这些基本概念和技术手段的指导下，国内外都出现了一批有关空间语义的微观研究。国外研究中，Hawkins (1984)基于空间认知对英语介词进行了全面研究。Vandeloise (1994)系统考

察了法语空间介词的句法结构和语义表征。Herskovits (1986)对英语的空间表达式进行了跨学科的调查。Svorou (1993)则从认知普遍性的角度对空间介词进行了跨语言比较研究。国内研究中，廖秋忠 (1986)引进参照点的概念研究方位词，突破了传统语法对方位词静态研究的局限。刘宁生 (1994)讨论了汉语如何选择空间方位的参照物、目的物和方位词，从而表达物体的空间关系。齐沪扬 (1998)建立了现代汉语空间系统的理论框架，极大地开拓了汉语空间语义研究的

鑲板€奸棟榑樹箝鑲界ü瀰氫 誤闕?/h2>

閨佻晶閨 鑲?strong>浣漏€呒漢緇塹殒鑑規磅鉏棋悒鍛
岫€讳紘鍍磅 ‘鑿罔垆錄 櫟澶�氫奸鑲?/strong>

- 褰嶳塹閨佻晶緇嶳瀰鑲?strong>紉 段鉏?strong>56.20%
鉏?/li>
- 涓よ QA 岫"瀰閨介€�緇 `2 answerable + 1 refusal`
鉏?/li>
- `235b` grounding 鑲翠赴婁★紉`32b` 鑲 繇 fallback
鉏?/li>

涓繪ā鑲?/strong>
qwen3-235b-a22b-instruct-2507

鑲為€€岫"瀰
qwen3-32b

緇攪
褰嶳塹緇x画淇濹寔
235b 涓洪觀總?QA

问答结果

问答

TASK_SPECIFIC

ANSWERED

适中

模型声明证据

模型	路由原因
qwen3-235b-a22b-instruct-2507	configured_ask_model
耗时	请求 ID
4171 ms	04236bc2c4814cedb267a52076845cab

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

已从 4 个片段构造上下文，涉及页码：1, 2, 5, 6。

Token 用量：输入 1795 / 输出 190 / 总计 1985

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

页码：1

CCL24-Eval任务3系统报告：基于大型语言模型的中文空间语义评测 霍世图1, 王钰君1, 吴童杰1 1北京师范大学国际中文教育学院 北京 摘要 本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识别任务，综合评估大模型的空间语义理解能力。其中，我们使用普通提示词、工作流 提示词和思维链三种提示词策略来探讨大模型的空间语义理解能力，最后发现ERNIE- 4在1-shot的普通提示词上表现最佳。最终，我们的...

打开定位

复制

页码：6

计算语言学 结果 模型总体表现 表3和表4分别是模型验证集、测试集的总体表现，满分为100。ERNIE-4借助1个样本的 普通提示得到53.88%，为本研究评测的最高分，而GLM-4在1个样本的工作流提示词得到了第 二高分 53.14%。最终测试集使用ERNIE-4和GLM-4进行预测，ERNIE-4达到了最高的准确率， 为56.20%。 根据所有模型的表现情况，我们总结归纳以下结论：（1）大模型其实能力是有差异且轻重缓急的，大模型的表现

、20260419_gold_ask_rank_accuracy.png` 镔氩氘浣揪愷鍊肩爬矜?+ citations鎔?

打开定位

复制

证据摘录

证据块：5e815278b9770464

最终，我们的方法排名第六，总体准确率得分为56.20%。

复制

证据块：3f9984aa8f05c325

最终测试集使用ERNIE-4和GLM-4进行预测，ERNIE-4达到了最高的准确率，为56.20%。

复制

- **Reliability Boundary**

绂婚 涓嶳紕闌狂紅錄陂酃 鑒 渾

- 閤佅晶鎢擊爬閣⊠⊠鑄?strong>鏈儿楠鏈攵嘿極橘嶷鑄
燂紵
- 妨€綯(二)酒鍛戒腑鏃讞紵緋葦稗涓嶳細纒⊠爬鑄岌€岫嶺
鎚存棧鎢擊爬鉅?/li>
- 漢規杓矜 e 姪錄嬭€岌■鑄岌竟鐄岫帶錄蹂拊鑒⊠獬璇僂
€y悅鏢烽噸瑕併€?/li>

鎢舵潴緇攪⊠鑼旂爬閫�氅緝嶠漢寮虹菟宸⊠紵鐄癸紵涓嶳嶺欽滄ā鏄�緇寮寮衡€濂紵紵岫
嶺欽滄瘡涓⊠栢璁洪尢鑄藉誤錄版杓矜 h 痾鎚⊠€過€?

鑒⊠€復禱褰囉細stats panel / API docs 浹咽
絛鎢⊠揀鑄岈笱杓浼富鑒鬱簍

Final Message: Answer, Cite,
Return To Evidence

问答结果

问答

NONE

REFUSED

适中

未返回可验证证据

执行路径

retrieval_gate (未调用模型)

路由原因

retrieval_no_match

耗时

10 ms

未返回可验证证据

本次回答未返回可验证的证据块，请谨慎使用结论。

当前问题与检索到的文档片段相关性不足，系统已拒绝无依据回答。

`20260419\_gold\_refusal.png` 鑄氮⊠榑榑榑榑⊠鑄庖 ‘鑄擊爬鑄穴
retrieval_status=no_match` 鎔?

