

研答通

带证据回链的论文 / 报告问答助手。核心能力不是“把答案说出来”，而是让每一条回答都能跳回 PDF 原文证据。

真实 replay

2 answered + 1 refused

默认 QA 模型

qwen3-235b-a22b-instruct-2507

为什么要做它

- 长文阅读慢，答辩和复核更需要“说得出处”。
- 普通聊天工具会给答案，但很难证明答案真的来自文档。
- 我们把“答案必须回到原文”做成了一条可验证链路。

锁定样例

中文论文 PDF

核心主线

ask → citation → PDF

补充验证

qwen3-32b 已验证可回退

评审重点

证据回链，不是泛化聊天

最短可验证链路

在当前真实运行环境下，已经验证通过的主路径是：**login → upload → ask → citation → PDF render → refusal**

1. Upload

上传论文或报告，保留原始文件与解析输出。

2. Parse

保存页级结构、文本分块与页面上下文。

3. Retrieve

先检索相关片段，未命中就直接拒答。

4. Answer

模型返回回答、used chunks 与 evidence quotes。

5. Cite

输出 citation、页码和原文片段。

6. Render

点击引用，直接回到 PDF 页面证据。

工程含义

不是概念图，已经在当前`.env`和真实模型上验证。

演示含义

评审先看到结果，再理解工程路径，不需要先听复杂架构。

权威报告

`gold\_sample\_replay\_real\_summary\_latest.md`

固定题集

2 answerable + 1 refusal

当前定位

论文 / 报告阅读与答辩准备

- Question 1

文档内问题先给答案，再给证据

锁定问题：这篇论文主要研究了什么问题？

- 系统先检索相关片段，再进入回答。
- 回答、citation、证据片段同步出现。
- 这一步已经证明它不是脱离文档的聊天壳。

评审要点 先展示“回答 + citation”同屏，再解释这是后端反查原文后的产物。

● Citation Jump

已定位到第 2 页 · 段落已高亮

证据片段

计算语言学 大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出 作为理论语言学新兴研究工具的潜力(Tjuatja et al., 2023)。在早期，大语言模型常被视为一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率(Bender et al., 2021)。然而后 续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信息(Piantadosi, 2023)，区分同一个词在...

计算语言学

大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出作为理论语言学新兴研究工具的潜力 (Tjuatja et al., 2023)。在早期，大语言模型常被视为一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率 (Bender et al., 2021)。然而后续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信息 (Piantadosi, 2023)，区分同一个词在不同语境中的多种用法 (Petersen and Potts, 2023)，甚至可以有效表征时间和空间 (Gurnee and Tegmark, 2023)。

空间语义评测是评估自然语言处理系统对空间表达理解能力的重要手段。传统的空间语义评测方法主要依赖人工标注，但这种方法标注成本高且可扩展性差。如今，基于生成式语言模型开展评测任务逐渐成为趋势。基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？

本研究基于第四届中文空间语义理解评测任务（SpaCE2024），首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

2 相关研究

这一部分首先介绍与空间语义有关的语言学研究，然后总结自然语言处理领域关于空间语义评测的研究概况。

证据能回到 PDF 原文

● citation 不只是页码，而是能打开真实页面。

● 页面内显示证据高亮，旁边保留原文片段文本。

● 这一步把“回答可信”变成“证据可看”。

对用户

可以快速确认答案出处，适合答辩和汇报前复核。

对评审

看得见 PDF 证据，比口头描述更有说服力。

- Question 2 + Model Choice

数值问题也能稳定回链

锁定问题：作者最终的方法排名和总体准确率分别是多少？

- 当前锁定结果：第六、56.20%。
- 两种 QA 模型都通过 `2 answerable + 1 refusal`。
- `235b` grounding 更丰满，`32b` 可作 fallback。

主模型	回退模型	结论
qwen3-235b-a22b-instruct-2507	qwen3-32b	当前继续保持 235b 为默认 QA

问答结果

问答 TASK_SPECIFIC ANSWERED 适中 检索上下文

模型 qwen3-235b-a22b-instruct-2507	路由原因 configured_ask_model
耗时 25 ms	请求 ID 21d55c2fde564870b566755bcf90e277

检索上下文
以下片段仅代表本轮检索命中的候选上下文，模型未完成证据声明。

本次结果命中本地缓存。

已从 4 个片段构造上下文，涉及页码：1, 2, 5, 6。

Token 用量：输入 1768 / 输出 198 / 总计 1966

检索上下文 (未完成证据声明)

以下片段仅代表本轮检索命中的候选上下文，模型未完成证据声明。

页码：1
CCL24-Eval任务3系统报告：基于大型语言模型的中文空间语义评测 霍世图1, 王钰君1, 吴童杰1 1北京师范大学国际中文教育学院 北京 摘要 本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识

● Reliability Boundary

问答结果

问答

NONE

REFUSED

适中

未返回可验证证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

retrieval_no_match

耗时

10 ms

请求 ID

51de1e187c024ac8ac345ca37e596e86

未返回可验证证据

本次回答未返回可验证的证据块，请谨慎使用结论。

当前问题与检索到的文档片段相关性不足，系统已拒绝无依据回答。

离题不编造，才叫可靠

- 锁定拒答问题：木星有几颗卫星？
- 检索未命中时，系统不会硬答，而是直接拒答。
- 对文档助手而言，边界控制和可验证性同样重要。

收束结论 研答通当前最强的差异点，不是“模型很强”，而是“每个结论都能回到文档证据”。

可选附录：stats panel / API docs 仅作支撑，不进主叙事

Final Message: Answer, Cite, Return To Evidence