

研答通

面向论文阅读、报告复核、答辩准备的文档问答助手。核心不是泛化聊天，而是让每条回答都能回到 PDF 原文证据。

锁定样例

中文论文 PDF

当前主链路

**upload → ask → citation → PDF
→ refusal**

为什么要做它

- 长文阅读成本高，关键信息分散，复核效率低。
- 普通聊天工具能给答案，但很难证明答案来自原文。
- 答辩和汇报场景里，真正重要的是“说得有依据”。

目标场景

**论文精读 / 报告复核
/ 答辩准备**

核心卖点

**答案、citation 与
PDF 证据同屏闭环**

当前主模型

**qwen3-235b-a22b-
instruct-2507**

回退模型

qwen3-32b

最短可验证链路

当前真实运行环境下，已经验证通过的 judge-facing 主链路是 **upload → ask → citation → PDF → refusal**。

Upload

上传论文或报告，保留原始文件与解析结果。

Structure

保留页级结构、文本分块与 PDF 页面上下文。

Ask

先检索相关片段，再调用模型回答问题。

Citation

同步返回页码、citation 与证据区。

PDF

点击 citation 后，直接回到 PDF 原页查看证据。

Refusal

检索无命中时直接拒答，不编造。

评审含义

不是概念图，而是当前环境里真实跑通过的闭环。

工程含义

解析、检索、引用校验和 PDF 呈现已经接成一条链。

锁定题组

2 个 answerable + 1 个 refusal

主样例

中文空间语义评测论文

主结论

问答必须回到原文，而不是停在生成

• Question 1

先给回答，再给证据

锁定问题：这篇论文主要研究了什么问题？

- 结果面板同时出现回答正文、citation 和证据区。
- 这不是脱离原文的聊天回复，而是带证据的文档问答。
- 回答的可信度来自“能回去看原文”，不是模型语气。

“评审第一眼要看到的不是模型会说话，而是它的回答和证据一起出现。”

问答结果

问答 TASK_SPECIFIC ANSWERED 适中 模型声明证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

configured_ask_model

耗时

79 ms

请求 ID

e4669e270ee246ef8992d07907b13295

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

本次结果命中本地缓存。

已从 4 个片段构造上下文，涉及页码：2, 3, 4, 11。

Token 用量：输入 2202 / 输出 289 / 总计 2491

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

PDF 预览

chinese_llm_spatial_eval.pdf

第 2 页 关闭预览

已定位到第 2 页 · 段落已高亮

证据片段

本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有何些优劣？

计算语言学

大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出作为理论语言学新兴研究工具的潜力 (Tjuatja et al., 2023)。在早期，大语言模型常被视为一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率 (Bender et al., 2021)。然而后续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信息 (Piantadosi, 2023)，区分同一个词在不同语境中的多种用法 (Petersen and Potts, 2023)，甚至可以有效表征时间和空间 (Gurnee and Tegmark, 2023)。

空间语义评测是评估自然语言处理系统对空间表达理解能力的重要手段。传统的空间语义评测方法主要依赖人工标注，但这种方法标注成本高且可扩展性差。如今，基于生成式语言模型开展评测任务逐渐成为趋势。基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有何些优劣？

本研究基于第四届中文空间语义理解评测任务 (SpaCE2024)，首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

2 相关研究

这一部分首先介绍与空间语义有关的语言学研究，然后总结自然语言处理领域关于空间语义评测的研究概况。

2.1 语言学视角下的空间语义研究

认知语言学基于人们对世界的经验和对世界进行感知和概念化的方法 (张敏, 1998)，借助隐喻等方式将抽象概念具象化。空间关系在认知语言学中占据了重要地位，是人类最早习得的能力之一 (Akhundov, 1986; Clark, 1973; 张敏, 1998; 赵艳芳, 2001)。Lakoff and Turner (1989)指出，作为一种意象图式隐喻 (image schema metaphor)，空间隐喻将具体的空间概念投射到抽象的语言结构中，这样的投射可以传递空间关系及其内在逻辑。这是空间语义形成的认知基础。⁰

具体来说，人在感知外部世界时总是对空间敏感，包括运动、方向、地点等信息。Langacker (1982)高度重视空间语义对语言形成的作用，提出空间语法 (Space Grammar)。Jackendoff (1983)的主题关系假设 (Thematic Relations Hypothesis, TRH) 认为人类语言概念结构中的事件 (event) 和状态 (state) 都是通过空间概念化组织起来的，所有语义场内的关系都类似空间组织关系。Lakoff (1987)的形式空间化假设 (SFH) 与之类似，并且更

把“能回答”变成“能验证”

- citation 不只是页码，而是一个可回跳的原文入口。
- PDF 面板同时保留原文片段和高亮位置。
- 对论文阅读和答辩场景来说，这一步才是真正的信任锚点。

区别于普通聊天工具

结果不是止于文本输出，而是能继续追到 PDF 里的证据位置。

● Question 2

具体数字也能回到原文

锁定问题：作者最终的方法排名和总体准确率分别是多少？

- 当前锁定答案：第六名、56.20%。
- 两个 QA 模型都通过了当前锁定题组。
- 默认保持 `qwen3-235b-a22b-instruct-2507`，同时保留 `qwen3-32b` 作为 fallback。

默认 QA

qwen3-235b-a22b-instruct-2507

Fallback

qwen3-32b

当前判断

两者都可用，235b 继续作为主路径默认值

问答结果

问答

TASK_SPECIFIC

ANSWERED

适中

模型声明证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

configured_ask_model

耗时

4171 ms

请求 ID

04236bc2c4814cedb267a52076845cab

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

已从 4 个片段构造上下文，涉及页码：1, 2, 5, 6。

Token 用量：输入 1795 / 输出 190 / 总计 1985

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

页码：1

CCL24-Eval任务3系统报告：基于大型语言模型的中文空间语义评测 霍世图1, 王钰君1, 吴童杰1 1北京师范大学国际中文教育学院 北京 摘要 本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识别任务，综合评估大模型的空间语义理解能力。其中，我们使用普通提示词、工作流 提示词和思维链三种提示词策略来探讨大模型的空间语义理解能力，最后发现ERNIE- 4在1-shot的普通提示词上表现最佳。最终，我们的...

打开定位

复制

页码：6

计算语言学 结果 模型总体表现 表3和表4分别是模型验证集、测试集的总体表现，满分为100。ERNIE-4借助1个样本的 普通提示得到53.88%，为本研究评测的最高分，而GLM-4在1个样本的工作流提示同得到了第 二高分 53.14%，最终测试集使用ERNIE-4和GLM-4进行预测，ERNIE-4达到了最高的准确率，为56.20%。根据所有

● Refusal

问答结果

问答 NONE REFUSED 适中 未返回可验证证据

执行路径

retrieval_gate (未调用模型)

路由原因

retrieval_no_match

耗时

10 ms

未返回可验证证据

本次回答未返回可验证的证据块，请谨慎使用结论。

当前问题与检索到的文档片段相关性不足，系统已拒绝无依据回答。

离题不编造，边界才可靠

- 锁定题组当前结果：2 answered + 1 refused。
- 拒答的意义不是“更会聊天”，而是把无依据问题挡在链路外。
- 项目的最终差异点仍然是：答案、citation 与 PDF 证据闭环。

结论

研答通不是一个更会说话的聊天壳，而是一个更能回证据的文档问答助手。