

研答通

面向论文阅读、报告复核、答辩准备的 evidence-backed 文档问答助手。
核心价值不是“更会聊天”，而是“每条回答都能回到 PDF 原文证据”。

锁定样例

中文论文 PDF

主叙事链路

**upload -> ask -> citation -> PDF
-> refusal**

当前定位

证据回链优先于泛化聊天

真实场景中的痛点

- 长文阅读成本高，关键信息分散，人工复核效率低。
- 普通聊天工具能给结论，但很难证明答案来自原文。
- 答辩和汇报场景最重要的不是“说得顺”，而是“说得出依据”。

最短可验证链路

- 1 上传论文或报告，保留页级结构。
- 2 先检索相关片段，再执行 ask。
- 3 同步返回 citation、页码和证据片段。
- 4 点击 citation 后直接回到 PDF 原页。

先给回答，再给证据，再回到 PDF

锁定文档为 `chinese\_llm\_spatial\_eval.pdf`，锁定问题 1 为“这篇论文主要研究了什么问题？”这一页只证明一件事：证据回链是真的。

问答结果

问答输出

复制结果

导出 Markdown

这篇论文基于第四届中文空间语义理解评测任务（SpaCE2024），主要研究大模型对空间语义的理解程度，以及不同模型在具体空间语义理解任务上的优劣，旨在了解大模型在空间语义理解方面的能力边界。

普通问答

只给结论，难核验、可能编造

研答通

1 条原文引用 · 可点回 PDF 第 1、2、3、11 页 · 离题自动拒答

● 原文证据支撑

● 基于 1 条原文引用，含 1 段逐字摘录

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

PDF 预览

第 1 页

缩小

125%

放大

手动高亮

清除本页

导出高亮

关闭预览

chinese_llm_spatial_eval.pdf

第 1 页

第 2 页

已定位到第 1 页

证据片段

基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？本研究基于第四届中文空间语义理解评测任务（SpaCE2024），首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

CCL24-Eval任务3系统报告： 基于大型语言模型的中文空间语义评测

霍世图¹, 王钰君¹, 吴童杰¹

¹北京师范大学 国际中文教育学院 北京 100875

{20222109017, 202221090022, 202221090014}@mail.bnu.edu.cn

摘要

本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识别任务，综合评估大模型的空间语义理解能力。其中，我们使用普通提示词、工作流提示词和思维链三种提示词策略来探讨大模型的空间语义理解能力，最后发现ERNIE-4在1-shot的普通提示词上表现最佳。最终，我们的方法排名第六，总体准确率得分为56.20%。

数值能回原文，离题会拒答，strict G3 可复现

最后一页把边界与稳定性说清楚：Q2 是具体数值题，refusal 走 retrieval_no_match，双模型决策和 strict G3 都已经锁定。



平台 · 无问芯穹 MaaS

DeepSeek/Qwen/Kimi/GLM
四家族实测 · request id 可对账

默认 QA

deepseek-v4-flash
(rollback: qwen3-235b)

strict G3

fresh-upload 6 / 6

对照「直接喂全文」

input token 仅 1/4.37 (准确率持平)

锁定判断

- Q2 证明系统不仅会概括，也能把具体数值落回原文。
- 主链路真实跑在无问芯穹 MaaS：默认 deepseek-v4-flash (V6 72题集 71/72)，rollback qwen3-235b (51题固定集 51/51) ——两个不同评测集，不混比。
- strict G3 六轮 fresh-upload 全通过，fallback 为 0 / 6。
- 近端真有本地 ML 算力 (BGE 句向量编码 + 混合检索、零云依赖)，云端只做生成——真端侧/云端协同，非纯云端网页。
- ask 主链路是单层 agentic 循环：模型自评证据→不足则有界二次重试，全程不破坏拒答/证据回链。