

研答通

面向论文阅读、报告复核、答辩准备的 evidence-backed 文档问答助手。
评审要记住的不是“更会聊天”，而是“每条回答都能回到 PDF 原文证据”。

锁定样例

中文论文 PDF

主叙事链路

**upload -> ask -> citation -> PDF
-> refusal**

当前定位

证据回链优先于泛化聊天

评审真正关心的痛点

- 长文阅读成本高，关键信息分散，人工复核效率低。
- 普通聊天工具能给结论，但很难证明答案来自原文。
- 答辩和汇报场景最重要的不是“说得顺”，而是“说得出依据”。

最短可验证链路

- 1 上传论文或报告，保留页级结构。
- 2 先检索相关片段，再执行 ask。
- 3 同步返回 citation、页码和证据片段。
- 4 点击 citation 后直接回到 PDF 原页。

先给回答，再给证据，再回到 PDF

锁定文档为 `chinese\_llm\_spatial\_eval.pdf`，锁定问题 1 为 “这篇论文主要研究了什么问题？” 这一页只证明一件事：证据回链是真的。

问答结果

问答 TASK_SPECIFIC ANSWERED 适中 模型声明证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

configured_ask_model

耗时

6396 ms

请求 ID

5363a0edc7074ef082148f84d6bda839

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

PDF 预览

第 2 页

关闭预览

chinese_llm_spatial_eval.pdf

已定位到第 2 页 · 段落已高亮

证据片段

本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？

计算语言学

大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出作为理论语言学新兴研究工具的潜力 (Tjautja et al., 2023)。在早期，大语言模型常被视为一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率 (Bender et al., 2021)。然而后续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信息 (Piantadosi, 2023)，区分同一个词在不同语境中的多种用法 (Petersen and Potts, 2023)，甚至可以有效表征时间和空间 (Gurnee and Tegmark, 2023)。

空间语义评测是评估自然语言处理系统对空间表达理解能力的重要手段。传统的空间语义评测方法主要依赖人工标注，但这种方法标注成本高且可扩展性差。如今，基于生成式语言模型开展评测任务逐渐成为趋势。基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？

本研究基于第四届中文空间语义理解评测任务 (SpaCE2024)，首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

2 相关研究

这一部分首先介绍与空间语义有关的语言学研究，然后总结自然语言处理领域关于空间语义评测的研究概况。

2.1 语言学视角下的空间语义研究

认知语言学基于人们对世界的经验和对世界进行感知和概念化的方法 (张敏, 1998)，借助隐

数值能回原文，离题会拒答，strict G3 可复现

最后一页把评审最关心的边界与稳定性说清楚：Q2 是具体数值题，refusal 走 retrieval_no_match，双模型决策和 strict G3 都已经锁定。

问答结果

问答

TASK_SPECIFIC

ANSWERED

适中

模型声明证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

configured_ask_model

耗时

6325 ms

请求 ID

605fd2f0feae45c193379aba6a02723a

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

已从 4 个片段构造上下文，涉及页码：1, 2, 5, 6。

Token 用量：输入 1794 / 输出 190 / 总计 1984

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

默认 QA

qwen3-235b-a22b-instruct-2507

Validated fallback

qwen3-32b