

研答通

面向论文阅读、报告复核、答辩准备的文档问答助手。核心不是泛化聊天，而是让回答、citation 与 PDF 原文证据形成闭环。

锁定样例

中文论文 PDF

主链路

upload → ask → citation → PDF → refusal

默认 QA

deepseek-v4-flash
(rollback: qwen3-235b)

验证结果

2 answered + 1 refused

“对论文和报告场景来说，重要的不是答案更像聊天，而是每条回答都说得出依据。”

为什么现有工具还不够

- 长文阅读成本高，关键信息分散。
- 普通聊天工具能回答，但很难证明答案来自原文。
- 答辩和汇报场景里，真正重要的是“说得出依据”。

我们怎么做

- 上传论文或报告，保留页级结构。
- 先检索相关片段，再生成回答。
- 同步返回 citation、页码和证据区。
- 点击 citation 直接回到 PDF 原页。
- 离题问题直接拒答，不编造。

锁定样例验证

PDF 预览

第 1 页 缩小 125% 放大 手动高亮 清除本页 导出高亮 关闭预览

chinese_llm_spatial_eval.pdf

第 1 页 第 2 页

已定位到第 1 页

证据片段

基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？本研究基于第四届中文空间语义理解评测任务（SpaCE2024），首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

CCL24-Eval任务3系统报告：
基于大型语言模型的中文空间语义评测

霍世图¹, 王钰君¹, 吴童杰¹
¹北京师范大学 国际中文教育学院 北京 100875
{20222109017, 202221090022, 202221090014}@mail.bnu.edu.cn

摘要

本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识别任务，综合评估大模型的空间语义理解能力。其中，我们使用普通提示词、工作流提示词和思维链三种提示词策略来探讨大模型的空间语义理解能力，最后发现ERNIE-4在1-shot的普通提示词上表现最佳。最终，我们的方法排名第六，总体准确率得分为56.20%。

关键词： 空间语义； 大语言模型； 提示词工程

System Report for CCL24-Eval Task 3: Evaluation of Chinese Spatial Semantics Based on Generative Language Models

citation 不是装饰，而是一个可回跳的 PDF 入口。评审能直接看到原页、证据位置和原文片段。

问答结果

问答输出 复制结果 导出 Markdown

这篇论文基于第四届中文空间语义理解评测任务（SpaCE2024），主要研究大模型对空间语义的理解程度，以及不同模型在具体空间语义理解任务上的优劣，旨在了解大模型在空间语义理解方面的能力边界。

普通问答

只给结论，难校验、可能编造

研答通

1条原文引用 · 可点回 PDF 第 1、2、3、11 页 · 离题自动拒答

原文证据支撑

基于 1 条原文引用，含 1 段逐字摘录

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

页码：1, 2

计算语言学 大语言模型具有较好的语义理解能力，与人类的语义判断具有极高的相关性，并展现出 作为理论语言学新兴研究工具的潜力(Tjuaatja et al., 2023)。在早期，大语言模型常被视为 一只“随机鹦鹉”，其学习机制是单纯统计某个词语出现的频率(Bender et al., 2021)。然而后 续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效整合语义和语法的多重信 息(Piantadosi, 2023)，区分同一个词在...

复制

证据摘录

证据块：e30e7a73c391c26a

基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型各有哪些优劣？本研究基于第四届中文空间语义理解评测任务（SpaCE2024），首先介绍空间语义评测的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行讨论和分析，以更好地了解大模型在空间语义理解方面的能力边界。

复制

查看运行细节

144 ms 展开

问答结果

检索无命中，拒绝回答

未在文档中检索到足够依据来回答这个问题。请换一个更贴近文档内容的问题，或上传更相关的文档。系统在文档中未找到与该问题相关的片段。

普通问答

多半会硬编一个看似合理的答案

研答通

检索无依据 → 主动拒答，绝不编造

查看运行细节

15 ms 展开

问答结果

问答输出 复制结果 导出 Markdown

最终的方法排名第六，总体准确率为56.20%。

普通问答

只给结论，难校验、可能编造

研答通

1条原文引用 · 可点回 PDF 第 1、2、5、6 页 · 离题自动拒答

原文证据支撑

基于 1 条原文引用，含 1 段逐字摘录

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

引用依据

以下片段来自模型声明实际使用的证据块，可用于回看依据。

页码：1

CCL24-Eval任务3系统报告：基于大型语言模型的中文空间语义评测 霍世图¹, 王钰君¹, 吴童杰¹ ¹北京师范大学 国际中文教育学院 北京 摘要 本研究的任务旨在让大模型进行实体识别、角色识别、异常识别、信息推理、同义识别任务，综合评估大模型的空间语义理解能力。其中，我们使用普通提示词、工作流提示词和思维链三种提示词策略来探讨大模型的空间语义理解能力，最后发现ERNIE-4在1-shot的普通提示词上表现最佳。最终，我们的方法排名第六，总体准确率得分为56.20%。