

● Evidence-Backed Ask

鏞旂爬閬?/h1>

甯—痾鏈 誤闕剧殒聰烘构 / 鐳ㄣ憐閬 爬鏢十墜銆俗忒蹇�冁鏶困笌
鐷 仛涓€涓 砸鏈€艳京澶ㄣ3 鏺劣€岃櫨聰十瘡涓€€鏼” 誤译疏迨鏼藉誤
錄? PDF 鏹燊构璇僂岷鏼�岃涓” 鐳聰烘构闕告 鎶僂姤鍛錒錒 鏼稿拑絳
旂京鍂� 鎶?

Locked Sample: chinese_llm_spatial_eval.pdf

Core Story: ask 鏼?citation 鏼?PDF

Fallback Verified: qwen3-32b

Current Stage: Competition Material Lock

閬 鏼岡

- 閬垮构闕告€鏼€紕閬峇涓€C侖鏼暎鏼出爬杈十墜澶嶺
 恧僂淩楂樆€/li>
- 鏼€€�京澶ㄣ伐鏼痾迨鏼�爬鏺�紕紕寰痾璇僂綵綵旂€
 鏼�簆浜�构杧 c €/li>
- 鏼一爬杈十滿鏼€嗽鏼出敕鏼风隅姝 i 漢瑕仛殒鏼€€涓€
 寰櫨駟澶�€€涓€€/li>

鎻規砗璽 緞

- 1 涓�紕結聰烘构鏼�姤鍛錒苟淇澶涓鏼燇€困欢鏼?/li>
- 2 璫 f 灑稜电駭緇撒澶鏼出敕鏼�构鏈€€塔鉤崙€/li>
- 3 閬峇€闕€€妨€綛€灑鏼痾鏈€€墁变点€/li>
- 4 杧旂誤鏼�爬鏼�itation 涓涓師鏼困墁变点€/li>
- 5 鏼瑰嚢 citation 璽冲誤 PDF 稜甸漢鏼�凍璇僂岷鏼?/li>
- 6 妨€綛€灑戒脗鏼刵涓綛ㄣ娈絳旂€/li>

鏼燡璦鏼蜂綵桶劣痾

问答结果

问答

TASK_SPECIFIC

ANSWERED

选中

模型声明证据

模型

qwen3-235b-a22b-instruct-2507

路由原因

configured_ask_model

耗时

79 ms

请求 ID

e4669e270ee246ef8992d07907b13295

模型声明证据

以下片段来自模型声明实际使用的证据块，可用于回查依据。

本次结果命中本地缓存。

已从 4 个片段构造上下文，涉及页码：2, 3, 4, 11。

Token 用量：输入 2202 / 输出 289 / 总计 2491

引用依据

以下片段来自模型声明实际使用的证据块，可用于回查依据。

PDF 预览

chinese_llm_spatial_eval.pdf

当前页码: 2 / 共 10 页

返回顶部

关闭预览

搜索内容

本预览器支持以下问题：1) 大模型输出内容是否准确反映了问题？2) 在理解问题语义的基础上，大模型是否准确回答了问题？

计算语言学

大语言模型具有较好的语义理解能力，与人类的语义判断具有高度的相关性，并表现出作为理论语言学新研究工具的能力 (Tjanaka et al., 2023)。在早期，大语言模型被视为“黑箱模型”，其学习机制是单纯统计某个词语出现的概率 (Bender et al., 2021)。然而后续的研究表明，大模型在没有遵循语言学理论的情况下，能够有效融合语义和语法的丰富信息 (Pontolillo, 2023)，这为同一问题在不同语境中的多解性 (Petersen and Potts, 2023)，甚至可以有效表征时间和空间 (Gurnee and Tegmark, 2023)。

空间语义理解是评估自然语言处理系统对空间表述理解能力的重要手段，传统的空间语义评测方法主要依赖人工标注，而这种方法往往成本高昂且可扩展性差。如今，基于生成式语言模型开展评测任务逐渐成为趋势，基于上述背景，本研究拟探究以下问题：1) 大模型对空间语义的理解程度如何？2) 在理解空间语义的具体任务上，大模型是否具备优势？

本研究基于第四届中国自然语言理解评测任务 (Space2024)，首先介绍空间语义理解的背景和相关研究，然后通过实验分析不同模型的空间语义理解能力，最后对实验结果进行详细分析，以更好地理解大模型在空间语义理解方面的能力边界。

2 相关研究

这一部分首先介绍与空间语义有关的语言学研究，然后总结自然语言处理领域关于空间语义评测的研究概况。

2.1 语言学视角下的空间语义研究

从语言学基于人们对世界的经验和对世界进行感知和概念化的方法 (能敏, 1986)，借助隐喻等方式将抽象概念具体化，空间关系在认知语言中占据了重要地位，是人类最早习得的能力之一 (Akhmetov, 1986; Clark, 1973; 张敏, 1998; 赵艳芳, 2001)。Lakoff and Turner (1989) 提出，作为一种意象图式隐喻 (image schema metaphor)，空间隐喻将具体的空间概念投射到抽象的语言结构中，这样的投射可以传递空间关系及内在逻辑，促进空间语义的形成与加巩固。¹

具体来讲，人在感知外部世界时总是对空间环境——包括运动、方向、地点等信息——Langacker (1982) 高度重视空间语义对语言形成的作用，提出空间语法 (Space Grammar)。Jackendoff (1983) 的主题关系假设 (Thematic Relations Hypothesis, TRH) 认为人类语言概念化结构中的事件 (event) 和状态 (state) 都是通过空间概念化组织起来的，所有语义场内的关系都类似空间组织关系。Lakoff (1987) 的形式空间化假设 (SFH) 与之类似，并且更进一步从空间语义的视角讨论了一些基本句型的形成。Johnson (1987) 提出了和空间语义相关的 27 个最重要的意象图式，认为这些图式是理解语言推理的基础。Potts and Dirven (1996) 也指出地点位置对人类概念的形成有基础性作用，很多和空间范畴相关的概念也已经成为认知语言学中的重要工具和分析手段。如 Talbot (1983) 的图形-背景理论，Langacker (1987) 的“整体-部分”“物体-目标”关系等。

在这些基本概念和理论指导下，国内外都出现了一批有关空间语义的文献研究。国外研究中，Hawkins (1984) 基于空间认知对英语介词进行了全面研究，Vanvalken (1994) 系统考察了法语空间介词的句法结构和语义表征，Hawkins (1986) 对英语的空间表述式进行了跨学科的研究。Swenson (1990) 则从认知语言学的角度对空间介词进行了跨语言比较研究。国内研究中，廖秋忠 (1986) 引进参照点的概念研究方位词，突破了传统语法对方位词静态研究的局限。刘宁生 (1994) 讨论了汉语如何选择空间方位的参照物、目的物 and 方位，从而表达物体的空间关系。李宇哲 (1996) 建立了用以描述空间关系的概念网络，进一步开展了汉语空间语义研究的研究。

汉语方位词“上”“下”始终是文献研究的重点，崔希亮 (2000) 对“在X上”进行解析，显示了其空间语义及其心理延伸，蓝纯 (2003) 比较了汉语的“上”“下”和英语的up/down，指出两种语言中相似方位词存在不同空间语义。白丽芳 (2006) 更加深入地考察了汉语的“上”和“下”，指出两者在跨语言系统中也有对应性，“上”比“下”更基本、语义更丰富。徐丹 (2006) 考察了汉语时空表达的语用特点，认为和其他语言相比，汉语特有的采用“上”“下”这样的纵向结构表示时间，体现了汉民族特有的知识。

“空间语义”和“空间范畴”是一组内涵和外延都类似的概念，本体研究中一般不作区分，如文献有必要，下文也不区分两者。

第二十三届中国自然语言学会大会论文集，第66页，第10页，太原，中国，2024年7月25日至28日。
1) 2024 年中国自然语言学会大会论文集，第66页，第10页，太原，中国，2024年7月25日至28日。

96

问答结果

问答

NONE

REFUSED

选中

未返回可能证据

执行路径

retrieval_gate (未调用模型)

路由原因

retrieval_no_match

耗时

10 ms

未返回可能证据

本次回答未返回可验证的证据块，请谨慎使用结论。

当前问题与检索到的文档片段相关性不足，系统已拒绝无依据回答。

鏼困。鏼响桄樯樯細鏼旂f 构旂艺itation鎧依愀鏼€墁变靛僂灑忸駟整般€?

鏼哄品樺櫨况

- 杧樺樺聰烘构涓€€旂旂ㄣ 浜団粗涓整桄樺樺紕`
- `浣涓€€涓漢緇樺殒鏼規砗鎶�悽鍛錒岷€紕缳鏼旁 `整迨塔鏼€
 櫨澶�氾旂旂
- `鏈儿櫨鏈€文嚟樺樺嶈鐷樺`

蹇撒墁鏼燡璦 replay 緇撒灑涓?`2 answered + 1 refused` 鏼岋br/> 苟涓?answerable 闕€€闕藉甫 citation 旂岷娈絳桄樺樺樹繚
 鏼?`retrieval\_status=no\_match` 鎶?

蹇撒墁緇撒灑

- 宸查撒璇?`login -> upload -> ask -> citation -> PDF
 render` 鎶?/li>
- 樺樺€ QA 涓?`qwen3-235b-a22b-instruct-2507` 鎶?/li>
- `qwen3-32b` 宸查撒璇僂灑浣灑涓 灑 fallback鎶?/li>
- 鏈€€寮哄樊癡僂鏼€痾鏈€€誤闕攢紕鏼�笌笌€砸鏈€艳京
 澶�€€/li>

閩僛戢鎚烘樞

璫烘杓綺捐

蹇?€增吳錄扮栢璫哄齏澶塹紆闌嶄綬鐳儿杓
妨€綽(=)垚鏈?€?/span>

鐳ㄣ儛澶嶡

鐳始爬澶嶡穿鐳燭杓璇僂嶇緇戕濂涓€€璧凤紆
鐳�奸涓涓昏?€鐳�祓鉅?/span>

絳旒京鍍嘴

鍍终爬闌?€嶇鍗脗澶嶡罇閿?PDF 涓
?€殒渚瀹�嶇鉅?/span>

欽漏 絳旒 鍍烔垠鋤燭杓铎劣€�笱鐳 仟鎼一斂鋤愐€僭€?

Core sources: `gold\_sample\_replay\_real\_summary\_latest.md`,
`gold\_sample\_qa\_compare\_latest.md`

Judging Story: Evidence-Backed Ask, Not
Generic Chat