

研答通

产品及技术文档

带证据回链的文档问答助手

无问芯穹 • 赛题一：端侧 / 云端协同应用

upload → ask → citation → PDF → refusal

版本日期：2026-06-05

作者：研答通项目组

目录

1. 作品概述	3
2. 产品能力	3
2.1 解决的真实问题	3
2.2 为什么这不是「聊天壳」	3
2.3 核心用户价值	3
2.4 目标场景	4
3. 系统架构：端云分层协同	4
3.1 三层职责划分	4
3.2 真实的端侧 ML 算力实体	4
3.3 诚实标注（口径自律）	4
4. 核心技术链路	4
4.1 文档解析	4
4.2 ask 路径：单层 agentic 检索循环	5
4.3 引用不可伪造	5
4.4 refusal：检索 / 模型双层拒答	5
4.5 上下文规划与 Token 压缩	5
5. 无问芯穹平台使用	5
5.1 接入与模型路由	6
5.2 真实留痕、可控台对账	6
5.3 多模型平台广度	6
6. 关键技术亮点与加分项	6
6.1 Token 消耗压缩	6
6.2 大模型与智能体能力	6
6.3 商业化潜力	6
7. 验证与评测体系	7
7.1 大规模压测 + 5 轮优化（2026-06-05）	7
7.2 评测诚实优先	7
8. 已知边界与诚实说明	8
8.1 短板一：多语言内容 → 过度拒答	8
8.2 短板二：多步表格数值推理	8
9. 结语与后续工作	8

1. 作品概述

研答通是一个面向**论文阅读、报告复核、答辩准备**的文档助手。它的核心能力不是泛化聊天，而是**带证据回链的 PDF 文档问答**——产品的立身点只有一句话：**答案必须能回到原文证据**。

围绕这条立身点，研答通把一次问答拆成可核验的四步主链路：

环节	做了什么
upload	上传 PDF / TXT / Markdown，近端解析并保留页级结构（block / line / bbox）
ask	近端先检索相关片段、组织上下文，再调用无问芯穹云端大模型作答
citation	回答附带 used_chunk_ids 与逐字 evidence_quotes，后端对每条引用做原文子串校验
PDF	点击 citation 跳回 PDF 原页，bbox 高亮定位证据所在位置
refusal	检索未命中 / 无真实依据时显式拒答，不做开放域硬答、不编造

一句话定位：**让每一个回答都能落回 PDF 原文的、可核验的文档问答助手**——面向学术与答辩场景「说得出处」的刚需。

2. 产品能力

2.1 解决的真实问题

论文与长报告的阅读复核，痛点不在「能不能给个答案」，而在「这个答案凭什么、出处在哪」。普通聊天工具会流畅作答，却说不出依据，也无法被核验——这在学术阅读、报告审核、答辩准备里恰恰是致命的。研答通正面解决这个问题：答得出，更要指得到原文。

2.2 为什么这不是「聊天壳」

研答通与套壳聊天工具的本质差异，是一条贯穿全链路的四层约束：

1. **解析层**：保留 PDF 页级结构与文本块，证据有坐标可定位
2. **检索层**：先选相关片段、再组织上下文，离题内容在生成前就被拦下
3. **生成层**：ask 路径要求模型返回结构化 evidence 依据，引用须逐字可校验
4. **呈现层**：citation 回到 PDF 页面并高亮证据位置，用户可一眼复核

只要检索未命中，系统**直接拒答**，而不是开放域硬答——这是产品可信度的底线。

2.3 核心用户价值

- 长文阅读时，快速定位核心信息，省去逐页翻找
- 问答时，答案能回到 PDF 原文证据，可核验、可追溯
- 离题或无依据问题，系统显式拒答，避免「一本正经地编造」
- 对答辩准备场景，citation → PDF 回链的价值高于泛化生成

2.4 目标场景

主路径为 **B 端高校实验室 / 课题组席位订阅**，辅以 **C 端答辩季入口**。差异化不是「答得流畅」，而是「答得可验证」——契合学术场景对「说得出处」的刚需（详见第 8 节商业化）。

3. 系统架构：端云分层协同

研答通是**端云分层协同**架构，正面回应赛题一「端侧 / 云端协同应用」命题：解析、切块、**本地语义编码**、混合检索、上下文压缩、证据定位等「重而可本地化」的计算放在端侧 / 近端完成；只把命中任务意图的**必要片段**上云，交由无问芯穹 MaaS 大模型**生成**；回答再回到端侧做 PDF 内证据回链。核心范式是**小模型在端理解、大模型在云生成**。

3.1 三层职责划分

层	位置	职责
端侧	浏览器 / 客户端	文件上传与任务输入、结果展示、PDF 证据 bbox 高亮叠加与坐标映射、手动标注与标注页导出、缩放翻页、本地会话态 (HttpOnly cookie)
近端服务	应用后端（部署节点本地，纯 CPU、零云依赖）	PDF 解析 (PyMuPDF 保留页级 block/line/bbox)、结构化切块、本地句向量编码 (BGE-small-zh-v1.5 ONNX)、词法 + 语义混合检索、上下文规划与 Token 压缩、bbox 子串定位与逐字证据校验、JSONL 调用日志
云端	无问芯穹 MaaS	ask / summary / outline 大模型生成；端侧 / 近端只上送必要片段

3.2 真实的端侧 ML 算力实体

近端跑一个**本地句向量模型 (BGE-small-zh-v1.5 ONNX)**做语义编码与混合检索，这是真实在本机 CPU 上运行的 ML 前向推理，**零云依赖、物理上可下沉到端侧 / 边缘节点**。本机实测：**权重 90.4 MB、每查询编码约 9 ms、纯 CPU**（建索引为一次性 / 文档级成本，走 warmup 预建）。模型缺失或失败时**自动回退纯词法**，现场绝不因端侧组件崩盘。

3.3 诚实标注（口径自律）

标注一：PDF 页面图像由近端用 PyMuPDF 栅格化后下发，端侧负责坐标映射与高亮 / 标注交互——端侧做的是「证据呈现 + 交互计算」，不夸大「端侧大模型推理」。

标注二：本地语义检索与我们高度调优的词法检索在固定基准上**持平、零回归**；其价值在于①**真实的端侧 ML 算力实体**；②对未知 / 改写措辞、词法弱区（英文公式、多语混排）的语义补召回。我们**不**把它包装为「检索显著提升」。

4. 核心技术链路

4.1 文档解析

- 支持 PDF / TXT / Markdown 三类输入
- PDF 解析保留页级结构 (block / line / bbox)，供 citation 与 PDF 回链使用
- 结构化切块：ChunkService 以 900 字为 target、100 字 overlap

4.2 ask 路径：单层 agentic 检索循环

1. 用户提问
2. 近端检索相关 chunk
3. 组织 ask 上下文，调用无问芯穹模型
4. **模型自评证据是否充分**：不足则给出 need_more=true（并在需要新证据时给 followup_query）
5. **有界二次重试 (iter ≤ 2)**：用 followup_query 补检索新片段（排除已用 chunk）再问一次；agent_iterations 落日志
6. 提取 used_chunk_ids / evidence_quotes，对每条 quote 做**原文子串校验**（校验不过即丢弃）
7. 组装 citation，回到 PDF 页面做 bbox 证据显示

诚实口径：改写补检索分支已实现且有单测覆盖，但固定 demo 集上模型多为单轮收敛、触发的二轮也多为同上下文复核，故生产日志 query_rewrites 多为空——我们定位为「有界自评重试」，不当作「现场可逐条核验改写」的卖点。

4.3 引用不可伪造

ask 返回的每条 evidence_quote，后端都会回到原文做**逐字子串校验**，校验不通过的引用直接丢弃——**引用无法被模型编造**。这是「答案能回到证据」从口号变成工程契约的关键一环。

4.4 refusal：检索 / 模型双层拒答

- **检索层**：无命中 → retrieval_gate 直接拒答，离题问题在生成前被拦截（同时省 token）
- **模型层**：检索命中但模型判定无依据 → llm_refused 二次拒答；低置信候选交模型复核，未给可验证证据则拒答

4.5 上下文规划与 Token 压缩

ContextPlannerService 按任务意图选片段（ask 走 retrieval、summary / outline 走 coverage），让**只有必要上下文上云**。这既是协同的核心节省环节，也直接对应加分项（详见第 6 节）。

5. 无问芯穹平台使用

研答通的主问答链路真实运行在无问芯穹 MaaS 之上，而非把平台「放进环境变量挂个名」。

5.1 接入与模型路由

项	取值
Base URL	https://cloud.infini-ai.com/maas/v1
默认 QA 模型	deepseek-v4-flash (V6 contract-patch holdout 后从 qwen3-235b 切换)
QA rollback	qwen3-235b-a22b-instruct-2507 (受信任回滚路径, gold-sample 双模型 3/3 即用它跑)
summary / outline	qwen3-235b-a22b-instruct-2507
历史 fallback	qwen3-32b / qwen3-next-80b-a3b-instruct (保留可用)

5.2 真实留痕、可控台对账

每次调用都把 token、latency、本地 request_id 与无问芯穹平台 request_id 落到 JSONL 日志 (data/logs/call_logs.jsonl)，可在 infinai 控制台逐条对账——「用了平台」因此能讲成「用了平台并留下可核验证据」。

5.3 多模型平台广度

同一检索流水线跨 DeepSeek / Qwen / Kimi / GLM 四大家族实测：6 模型 × 10 题 = 60 次真实调用、均带 request_id、全部答对 (multi_model_eval.md)，证明真实深度使用平台、非单模型挂名。

6. 关键技术亮点与加分项

6.1 Token 消耗压缩

近端「解析 → 切块 → 按任务意图选片段」三层预处理，让只有必要上下文上云：长文档 ask 平均节省 86.6% input token、峰值 93.1% (Attention 论文 10,263 → 704 tokens)。

更硬的口径 (真实平台 token, 非 tiktoken 估算)：受控对照「直接喂全文」，唯一变量是检索接地 vs 全文——22 题集省 4.37× (49,273 vs 215,113, 准确率 22/22 持平)；扩到 39 题真实论文集省 4.3× (RAG 38/39, 唯一子串漏配已核验非真失败)，每条调用带真实 chatcmpl-id 可对账。

诚实标注：口径是「同等准确度下省 4.3-4.4× + 能 scale + 能 bbox 回链」，不是「RAG 更准」；短文档场景如实标注为约 -4% (单 chunk 加页码 / 标题 marker 略增)，不假装所有场景都压得动。

6.2 大模型与智能体能力

主链路使用无问芯穹大模型 + 单层 agentic 检索循环 (检索 → 模型自评证据是否充分 → 有界二次重试 iter ≤ 2, 需新证据时改写 followup_query 补检索) + 检索 / 模型双层拒答; agent_iterations 落日志 (真实日志中约 1/4 的 ask 触发了二轮自评)。

6.3 商业化潜力

主打 B 端高校实验室 / 课题组席位订阅 + C 端答辩季入口。差异化是「答得可验证」（bbox 级回链 + 逐字校验 + 离题拒答）；毛利侧由 token 压缩支撑（每次问答边际推理成本压低近一个数量级）。完整市场量级 / 竞品差异 / 单位经济见 COMMERCIALIZATION_CASE.md。

7. 验证与评测体系

我们把评测当成**找自己问题的工具，而不是包装分数的工具**。验证从锁定小样本一路放大到 3 万级对抗压测，且层层人复核：

层级	规模	结果与口径
gold-sample 双模型	3 题	235b 3/3、32b 3/3，最强可复现 demo 证据
strict G3 复现	6 轮	6/6 连续 strict fresh-upload，每轮新 file_id，fallback 0/6
扩展评测	51 题	默认 deepseek-v4-flash 48/51（94.1%）；V6 extreme holdout 71/72、拒答精确率 100%、引用 98.3%；rollback qwen3-235b 51/51
judged 三层交叉 + 人复核	176 题泛化	强模型现造全新题判分 88.6%，48 道拒答陷阱 0 编造，主动暴露弱点
端侧 A/B	176 题	端侧语义检索把过度拒答 6→1（0 新增编造），固定集零变化
大规模压测 + 5 轮优化	33,838 题	整体 91.0% 初判通过，16 类文档 14 类 89 - 99%
多模型广度	60 次	DeepSeek / Qwen / Kimi / GLM 四家族同流水线全过

7.1 大规模压测 + 5 轮优化（2026-06-05）

用代金券把「找短板 → 验证 → 优化迭代」跑到底：累计 **33,838 道全新对抗题**（真实计费、request_id 可对账），其中 **7000+ 道经强模型判分式严格评测**（≈ 1.4 万次真实调用）。方法是：强模型现造题 → 真实生产链路作答 → 强模型带原文页判分 → **人逐个复核 FAIL**。

针对发现的「过度拒答」短板，做了 **5 轮提召回实验**（端侧 bge-small / 云端 bge-m3 / 调救援阈值 / 短文档全文兜底），结论跨方案一致：

任何「检索空时给模型更多上下文」的方案，都会让模型在对抗性无依据题上过度推断 → 幻觉上升。所以「**检索空就拒答**」是**精度 / 召回权衡的安全侧**，是本产品「**证据可核验、不编造**」立身点的**正确选择**，验证为对、保持默认不动。这不是没优化成，是有意不塞伤害产品的改动。

7.2 评测诚实优先

过程本身暴露了一个方法论发现：**强模型裁判在难数值题上自己也会算错**（finance 类失败约一半是裁判误判），所以 90% 初判通过率被低估、真实系统质量更高。结论：**judged-eval 必须人复核，不能直接拿 pass-rate 当系统准确率**。

8. 已知边界与诚实说明

我们不说「没有短板」，而是主动找到、量化短板，并证明当前设计是正确取舍。两个真短板在 3 万题尺度上稳定复现，且都不在锁定 demo 主链路（中文论文问答）上。

8.1 短板一：多语言内容 → 过度拒答

- **现象：**词法检索对非中英文召回弱 → 检索空 → 拒答（multilingual 类约 80%、254 道过度拒答）
- **取舍：**已用 5 轮实验证明全局提召回会增幻觉，故保持安全默认
- **可选修复：**在确为弱词法 / 多语言场景，端侧语义检索能干净补召回（专项 A/B 9→0、零新幻觉）——这是端云协同的真实价值，作选项不作默认

8.2 短板二：多步表格数值推理

- **现象：**finance 类多行 / 多条件表格算术会误读单元格 / 漏行（约 59%）
- **定性：**属大模型自身能力边界——连我们的强裁判 qwen3-235b 在同类题上也算错，非检索 / 配置可修
- **后续路线：**结构化表格解析 + 受约束计算器 + 单元格级溯源（让模型调工具算，而非脑算）。这是加功能、不是赛前 prompt 热补，列为 roadmap

9. 结语与后续工作

研答通用一条**可核验的主链路**（upload → ask → citation → PDF → refusal）+ 一个**真实的端侧 ML 实体**，把「端云协同」从叙事做成了可演示、可复现、可追溯的工程事实。后续不再以扩功能为主，而以把现有能力升级为证据链为主：

1. 3 页 PPT 与 5 分钟视频正式成片
2. 如最终演示环境变化，刷新四张核心截图
3. 多语言召回：端侧语义检索可选开关（已验证干净），默认关以保安全
4. 表格数值：后续接结构化表格解析 + 计算器工具链
5. 保持各材料与 strict G3 / 默认模型口径一致

evidence-backed QA • 可演示 • 可复现 • 可追溯